MINISTERUL EDUCAȚIEI

UNIVERSITATEA TEHNICĂ
DIN CLUJ-NAPOCA
FACULTATEA DE AUTOMATICĂ ȘI CALCULATOARE

DRIVER ASSISTANCE SYSTEM

PROIECT DE SEMESTRU

Student: **Bianca RIȘCO**

Disciplina: **Sisteme bazate pe Cunoaștere**

2026

Cuprins

1 INTRODUCERE 2

1.1 CONTEXT GENERAL 2
1.2 OBIECTIVE 3
1.3 SPECIFICAȚII 4
1.3.2 Specificații Tehnice și de Performanță 4
1.3.3 Structuri de Date și Interfață 5
1.3.4 Limitări și Constrângeri 5

2 CUNOAȘTEREA ȘI ANALIZA SETULUI DE DATE 6

2.1 Descrierea Setului de Date și Mediul de Implementare 6
2.2 Statistici Descriptive și Structura Datelor 6
2.3 Analiza Calității Datelor 8
2.4 Analiza Corelațiilor 8
2.5 Analiza Vizuală a Scenariilor Rutiere 8

3 PRE-PROCESAREASETULUI DE DATE 10

3.1 Redimensionarea și Standardizarea Dimensională 10
3.2 Eliminarea Zgomotului (Filtrarea) 11
3.3 Augmentarea Datelor (Data Augmentation) 11
3.4 Normalizarea și Pregătirea Tensorilor 12

4 MODELAREA SISTEMULUI 13

4.1 DETALII REFERITOARE LA ETAPA DE MODELARE 13
4.1.1 Arhitectura Rețelei Neurale 13
4.1.2 Metodologia de proiectare: Training from Scratch 14
4.1.3 Calcule și Tehnici: Normalizarea Z-Score 14
4.2 IMPLEMENTARE 15
4.2.1 Mediul de implementare 15
4.2.2 Managementul Datelor (Proceduri) 15
4.3 EVALUAREA MODELULUI 16
4.3.1 Metodologia de evaluare: Metode și Metrici 16
4.3.1.1 Dice Loss (Funcția de Pierdere) 16
4.3.1.2 IoU (Intersection over Union) 16
4.3.1.3 Matricea de Confuzie (Confusion Matrix) 16
4.3.2 Experimente și Analiza Rezultatelor 16
1. Evoluția Erorii (Dice Loss) 17
2. Analiza Performanței prin Metrica IoU 17
3. Analiza Critică prin Matricea de Confuzie 18

5 CONCLUZII 22

5.1 REZULTATE OBȚINUTE 22
5.2 DIRECȚII DE DEZVOLTARE 23

6 BIBLIOGRAFIE 24

1 Introducere

1.1 Context general

Industria auto traversează în prezent una dintre cele mai revoluționare perioade din istoria sa, marcată de tranziția de la vehiculele convenționale la cele definite prin software (*Software-Defined Vehicles*). În centrul acestei transformări se află sistemele avansate de asistență a șoferului (ADAS - *Advanced Driver Assistance Systems*) și conducerea autonomă, tehnologii care promit să redefinească siguranța rutieră și eficiența transportului. Motivația fundamentală a acestui proiect izvorăște dintr-o pasiune profundă pentru universul auto și pentru mecanismele software complexe care animă mașinile și motocicletele moderne. Curiozitatea de a înțelege nu doar „cum" se deplasează un vehicul, ci „cum gândește" și cum percepe mediul înconjurător, a constituit impulsul principal în alegerea acestei teme.

Lucrarea de față se plasează în contextul larg al sistemelor de transport inteligente (*Intelligent Transportation Systems*), unde capacitatea unui vehicul de a interpreta corect scena rutieră este critică. Importanța studiului derivă din necesitatea imperioasă de a reduce numărul accidentelor rutiere cauzate de eroarea umană. Sistemele de percepție vizuală, bazate pe inteligență artificială, au devenit „ochii" vehiculelor autonome, fiind responsabile pentru detectarea benzilor de circulație, a obstacolelor și a semnalizării rutiere în timp real.

Am ales implementarea unui model de **segmentare semantică** deoarece aceasta reprezintă una dintre cele mai sofisticate și complete metode de procesare a imaginii. Spre deosebire de simpla detecție a obiectelor (care încadrează elementele în chenare), segmentarea semantică oferă o înțelegere la nivel de pixel, clasificând fiecare punct din imagine ca fiind „drum", „mașină", „marcaj" sau „fundal". Această granularitate este esențială pentru funcții critice precum menținerea benzii (*Lane Keep Assist*) sau frânarea automată de urgență, deoarece oferă vehiculului informații precise despre geometria drumului și spațiul liber disponibil.

Din punct de vedere teoretic, lucrarea explorează eficiența rețelelor neurale convoluționale profunde (Deep Learning), utilizând o arhitectură consacrată de tip **U-Net** cu un encoder **ResNet34**, abordare de tip **Training from Scratch**, în care arhitectura este antrenată exclusiv pe setul de date rutier colectat. Această metodă a fost aleasă pentru a asigura o specializare maximă a filtrelor convoluționale pe caracteristicile vizuale specifice mediului de testare, eliminând orice bias extern provenit de la seturi de date generaliste precum ImageNet.Lucrarea este structurată astfel încât să ghideze cititorul de la concepte teoretice la implementarea practică:

- **Capitolul 1** prezintă fundamentele teoretice ale vederii computerizate și arhitecturile de rețele neurale utilizate.
- **Capitolul 2** detaliază metodologia de pregătire a datelor, tehnicile de preprocesare și augmentare necesare pentru a asigura robustețea modelului.
- **Capitolul 3** descrie implementarea modelului de segmentare și procesul de antrenare.
- **Capitolul 4** analizează rezultatele obținute prin metrici specifice (IoU, Loss) și demonstrează funcționalitatea modulului de decizie ADAS în scenarii reale.
- **Capitolul 5** prezintă concluziile și direcțiile viitoare de dezvoltare.

1.2 Obiective

Obiectivul general al acestei lucrări este dezvoltarea și validarea unui sistem complet de percepție și asistență pentru conducerea autonomă, capabil să interpreteze scene rutiere complexe și să ia decizii de siguranță în timp real. Pentru atingerea acestui scop, au fost stabilite următoarele obiective specifice:

1. **Dezvoltarea unui model robust de segmentare semantică:** Implementarea unei arhitecturi de tip U-Net capabile să identifice și să segmenteze cu precizie ridicată clasele de interes critic: suprafața drumului, vehiculele, semnele de circulație și marcajele rutiere.

2. **Optimizarea setului de date și a procesului de antrenare:** Aplicarea unor tehnici avansate de preprocesare (denoising pentru simularea senzorilor reali) și augmentare a datelor (modificări geometrice și de iluminare) pentru a crește capacitatea de generalizare a modelului în condiții variate de mediu.

3. **Implementarea unui Sistem Expert pentru decizii ADAS:** Integrarea predicțiilor vizuale ale modelului neural într-un modul logic bazat pe reguli (*Rule-Based System*). Acesta are rolul de a interpreta densitatea traficului și vizibilitatea drumului pentru a emite alerte specifice (ex: „LANE ASSIST WARNING", „EMERGENCY BRAKE").

4. **Evaluarea performanței utilizând metrici standardizate:** Validarea modelului folosind metrica *Intersection over Union (IoU)* și Matricea de Confuzie pentru a asigura fiabilitatea detecției și pentru a identifica limitările curente ale sistemului.

5. **Demonstrarea aplicabilității în scenarii reale:** Testarea sistemului integrat pe imagini noi, neîntâlnite în antrenament, pentru a simula comportamentul unui vehicul autonom în trafic și pentru a analiza impactul distribuției elementelor rutiere asupra siguranței

1.3 Specificații

Pentru a atinge obiectivele propuse, sistemul a fost proiectat respectând un set riguros de specificații funcționale și tehnice, menite să asigure o interpretare corectă a mediului rutier și o luare a deciziilor în timp util. Arhitectura sistemului este modulară, separând componenta de percepție vizuală (bazată pe rețele neurale de tip Deep Learning) de cea decizională (bazată pe un Sistem Expert cu logică simbolică).

1.3.1 Specificații Funcționale

1. **Segmentare Semantică Multi-Clasă:** Identificarea și clasificarea fiecărui pixel din imaginea video captată într-una dintre cele 6 clase de interes: Background (Fundal/Cer), Road Sign (Semne), Car (Vehicule), Marking (Marcaje), Road Surface (Asfalt/Drum), Vegetation (Vegetație).
2. **Analiza Contextuală a Traficului:** Calculul în timp real al densității vehiculelor (procentul de ocupare în câmpul vizual) și monitorizarea vizibilității benzii de rulare pentru prevenirea părăsirii carosabilului.
3. **Sistem de Alertare ADAS (Advanced Driver Assistance System):** Generarea automată a mesajelor de avertizare în funcție de scenariul detectat de sistemul expert:
    - **SAFE:** Condiții optime, recomandare Cruise Control.
    - **WARNING:** Trafic moderat (5-15% densitate), recomandare Prepare Brake.
    - **DANGER:** Risc de coliziune (>15% densitate), recomandare Emergency Brake.
    - **CRITICAL:** Pierderea vizibilității drumului (<15% vizibilitate), alertă Lane Assist Warning.

1.3.2 Specificații Tehnice și de Performanță

- **Arhitectură Model: U-Net** – o arhitectură de tip encoder-decoder care permite localizarea precisă a obiectelor.

- **Backbone (Encoder): ResNet34**, inițializat aleatoriu (folosind metoda He Initialization). Procesul de învățare pornește fără cunoștințe pre-existente, rețeaua fiind forțată să extragă trăsături vizuale (muchii, texturi) direct din distribuția de pixeli a setului de date propriu, stabilizată prin normalizarea Z-score

- **Dimensiuni și Parametri:** Imaginile de intrare sunt standardizate la rezoluția **640x640 pixeli**. Detaliile structurale ale modelului sunt prezentate în **Sumarul Arhitecturii Neurale (ResNet34 + U-Net):**

- **Metrica de Evaluare:** Performanța este cuantificată prin scorul **IoU (Intersection over Union)**, vizând un prag de >90% pentru clasele critice (Vehicul, Drum).

- **Funcția de Pierdere:** Utilizarea **Dice Loss** pentru a gestiona dezechilibrul inerent al claselor din imaginile rutiere.

1.3.3 Structuri de Date și Interfață

- **Manipularea Datelor:** Sistemul operează intern pe tensori multidimensionali (*PyTorch Tensors*) pentru procesarea GPU, iar măștile rezultate sunt convertite în matrici *NumPy* pentru analiza logică.

- **Mapping Semantic:** Utilizarea dicționarelor de tip Hash Map (color2id și id2color) pentru translatarea eficientă O(1) între valorile pixelilor RGB și ID-urile claselor.

- **Interfața Utilizator:** Ieșirea sistemului este o interfață vizuală compusă ("Split Screen") care prezintă simultan realitatea (stânga) și interpretarea AI (dreapta), suprapusă cu decizia algoritmică.

1.3.4 Limitări și Constrângeri

- **Dependența de Iluminare:** Performanța sistemului optic poate fi afectată în condiții de lumină extremă (noapte, ceață densă sau *glare*), deși s-au integrat tehnici de augmentare (RandomBrightnessContrast) pentru a spori robustețea.

- **Ambiguități Semantice (False Positives):** Există o limitare inerentă setului de date, unde fundaluri complexe (ex: cer albastru senin) pot fi ocazional clasificate eronat ca semne de circulație.

- **Resurse Computaționale:** Datorită numărului mare de parametri (24.4 milioane) și a rezoluției de 640x640, inferența în timp real necesită accelerare hardware (GPU compatibil CUDA).

2 Cunoașterea și analiza setului de date

2.1 Descrierea Setului de Date și Mediul de Implementare

- **Sursa Datelor:** Setul de date constă în imagini rutiere captate din perspectiva șoferului, simulând o cameră de bord. Fiecare imagine este însoțită de o **mască de segmentare** (Ground Truth), unde fiecare pixel este etichetat cu o culoare specifică clasei din care face parte. Totodata, setul de date original conține și aceste fișiere (csv, xml), dar pentru antrenarea rețelei neurale U-Net am utilizat **măștile de segmentare rasterizate** (imaginile PNG din folderul masks), deoarece rețelele convoluționale lucrează cu pixeli, nu cu coordonate vectoriale XML.

- **Mediul de Implementare:**
    - **Limbaj:** Python, ales pentru ecosistemul său vast în AI.
    - **Framework: PyTorch**, utilizat pentru manipularea tensorilor și construcția rețelei neurale, facilitând accelerarea hardware.
    - **Hardware:** Antrenarea s-a realizat pe o arhitectură **CUDA** (GPU), esențială pentru procesarea paralelă a milioanelor de parametri ai rețelei U-Net.
    - **Biblioteci:** OpenCV (procesare imagini), Albumentations (augmentare date), Segmentation Models PyTorch (arhitectură model), Matplotlib (vizualizare).

2.2 Statistici Descriptive și Structura Datelor

- **Dimensiuni:** Imaginile originale au rezoluții variate, însă pentru uniformizarea intrărilor în rețeaua neurală, acestea au fost redimensionate standardizat la **640x640 pixeli**. Această dimensiune reprezintă un compromis optim între păstrarea detaliilor fine (necesare pentru semnele de circulație).

- **Clasele Semantice:** Setul de date este adnotat pentru 6 clase de interes, definite printr-o mapare cromatică RGB specifică.

ID	Nume	RGB
0	Clasa 0	(0, 0, 0)
1	Clasa 1	(255, 53, 9
2	Clasa 2	(255, 204,
3	Clasa 3	(221, 255,
4	Clasa 4	(61, 61, 24

Figura 2.1. Clasificarea claselor

➔ **Negru → Clasa: Background (Fundal)**
➔ **Roșu / Roz) → Clasa: Road Sign (Semne de circulație)**
➔ **Galben → Clasa: Car (Vehicule)**
➔ **Verde Lime → Clasa: Marking (Marcaje Rutiere)**
➔ **Albastru → Clasa: Road Surface (Asfalt / Drum)**
➔ **Mov → Clasa: Vegetation (Vegetație)**

- **Împărțirea Datelor (Data Split):** Pentru a asigura o evaluare obiectivă, setul de date a fost divizat în trei submulțimi:
  - **Antrenare (Train):** 21 de imagini (70%) - folosite pentru ajustarea greutăților.
  - **Validare (Val):** 5 imagini (15%) - folosite pentru monitorizarea antrenării și ajustarea hiperparametrilor (Scheduler).
  - **Testare (Test):** 5 imagini (15%) - folosite exclusiv pentru evaluarea finală și generarea matricii de confuzie.

➔ Train: 21 | Val: 5 | Test: 5

- **Histograma Distribuției Claselor**: Pentru a înțelege compoziția semantică a setului de date, a fost realizată o analiză statistică a distribuției pixelilor pentru fiecare clasă, rezultatele fiind ilustrate în **figura:**

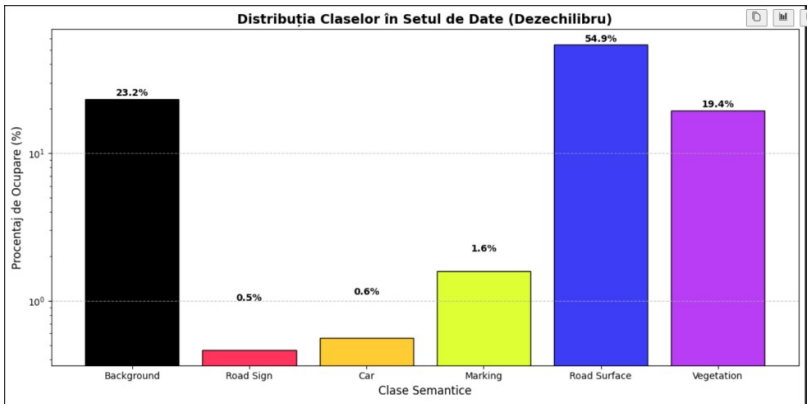

Figura 2.3. Histograma Distribuției Claselor

➔ Analiza acestei histograme relevă un **dezechilibru sever al claselor** (*Class Imbalance*):

- **Clasele Majoritare:** *Road Surface* (Drum) și *Background* (Fundal) ocupă majoritatea suprafeței imaginilor.

- **Clasele Minoritare:** Elementele critice pentru siguranță, precum *Road Sign* (Semne) și *Marking* (Marcaje), reprezintă o fracțiune infimă din totalul pixelilor (sub 1-2%).

2.3 Analiza Calității Datelor

- **Verificarea Integrității:** În etapa preliminară, s-a implementat un script automatizat de validare care a parcurs perechile imagine-mască.
- **Procedură:** S-a verificat existența fișierelor, corespondența numelor și capacitatea de a fi citite de biblioteca OpenCV.
- **Rezultat:** În urma procesului, au fost validate 31 imagini curate, gata pentru procesare.

  ➔ Se execută verificarea calității datelor...
  ➔ Validare completă. Imagini valide: 31 din 31

2.4 Analiza Corelațiilor

- Analizând distribuția pixelilor în măștile de segmentare, se observă un **dezechilibru major al claselor**.
  - Clasele "Background" (Cer) și "Road Surface" (Asfalt) ocupă majoritatea pixelilor din imagini (adesea peste 80-90%).
  - Clasele critice precum "Road Sign" sau "Marking" ocupă o fracțiune infimă (sub 1-2%).

- **Soluție adoptată:** Această analiză a motivat alegerea funcției de pierdere **Dice Loss**, care penalizează erorile bazate pe suprapunere (IoU), nu pe numărul brut de pixeli, oferind astfel o șansă egală claselor mici să fie învățate.

2.5 Analiza Vizuală a Scenariilor Rutiere

O analiză vizuală calitativă a setului de date este esențială pentru a înțelege contextul în care modelul neural va trebui să opereze. Această etapă ne permite să identificăm nu doar punctele forte ale datelor, ci și lipsurile care pot limita performanța sistemului în condiții reale.

Variabilitatea:

- **Diversitate Geografică:** Imaginile prezintă o varietate de decoruri, incluzând drumuri extra-urbane de vegetație densă (reprezentată prin culoarea mov) și segmente de drum.
- **Perspectiva Camerei:** Toate cadrele respectă perspectiva *POV (Point of View)* de la nivelul parbrizului.

- **Contrastul Obiectelor:** Se observă un contrast vizual bun între suprafața carosabilă (albastră) și restul elementelor de decor, ceea ce facilitează sarcina de segmentare a modelului U-Net.

Deşi setul de date acoperă bine scenariile de drum liber, analiza vizuală a relevat câteva limitări critice:

- **Absența Traficului Dens:** Majoritatea cadrelor prezintă un flux de trafic scăzut sau moderat. Lipsa imaginilor cu ambuteiaje, unde vehiculele (galbene) se suprapun sau ocupă majoritatea câmpului vizual, limitează capacitatea modelului de a învăța separarea instanțelor în condiții de aglomerație.
- **Lipsa Complexității Urbane:** Nu au fost identificate intersecții complexe, sensuri giratorii sau zone cu pietoni. Aceste elemente sunt vitale pentru un sistem ADAS robust, deoarece forțează modelul să recunoască tipare geometrice variate, nu doar linii paralele de drum.
- Se poate observa o comparație între **o imagine originală**, captată de camera video a vehiculului, și **masca de segmentare** corespunzătoare.

Figura 2.3. Analiza vizuală a setului de date

3 Pre-procesareasetului de date

Etapa de pre-procesare reprezintă un pas critic în fluxul de lucru al învățării profunde (*Deep Learning*), având rolul de a transforma datele brute într-un format standardizat, compatibil cu arhitectura rețelei neurale, și de a îmbunătăți calitatea informației prin eliminarea zgomotului și diversificare artificială.

Dată fiind dimensiunea redusă a setului de date disponibil (31 de imagini), strategia de pre-procesare s-a concentrat pe două obiective majore: **Standardizarea** (pentru consistența tensorilor) și **Augmentarea** (pentru evitarea fenomenului de *Overfitting*).

3.1 Redimensionarea și Standardizarea Dimensională

Rețelele neurale convoluționale necesită intrări de dimensiuni fixe pentru a putea procesa datele în loturi. Imaginile originale prezentau rezoluții variate, incompatibile cu arhitectura U-Net.

- **Metoda aplicată:** Redimensionarea (*Resizing*) uniformă la rezoluția de **640x640 pixeli**.
- Această rezoluție a fost aleasă ca un compromis optim între fidelitatea detaliilor (necesară pentru identificarea obiectelor mici, precum semnele de circulație) și eficiența computațională.
- **Detalii:**
    - Pentru **Imaginile RGB**, s-a utilizat interpolarea liniară (cv2.INTER_LINEAR). Aceasta calculează media culorilor pixelilor vecini.
    - Pentru **Măștile de Segmentare**, s-a utilizat interpolarea de tip Nearest Neighbor (cv2.INTER_NEAREST). Aceasta este esențiala deoarece măștile conțin valori discrete (ID-uri de clasă: 0, 1, 2...), iar o interpolare liniară ar fi creat valori intermediare (ex: 1.5) care nu au sens semantic.

3.2 Eliminarea Zgomotului (Filtrarea)

Imaginile captate de camerele de bord pot conține zgomot digital cauzat de senzor, condiții de lumină slabă. Zgomotul excesiv poate induce în eroare rețeaua neurală, generând muchii false.

- **Metoda aplicată:** Filtru Median (Median Blur).
- S-a utilizat funcția cv2.medianBlur din biblioteca OpenCV, aplicată exclusiv pe imaginea de intrare (nu și pe mască), cu un nucleu de dimensiune mică.
- Această tehnică netezește imaginea (precum in exemplul de mai jos), eliminând zgomotul de tip "sare și piper", păstrând în același timp contururile obiectelor, aspect esențial pentru segmentarea precisă a mașinilor și a drumului.
- Filtrul Median nu face media, ci alege valoarea din mijloc. Dacă este o muchie clară, o păstrează intactă.

Figura 3.1. Imaginile inainte și dupa aplicarea filtrului Median

3.3 Augmentarea Datelor (Data Augmentation)

Având în vedere numărul limitat de eșantioane de antrenament (21 imagini), riscul ca modelul să memoreze datele (*Overfitting*) în loc să învețe trăsături generale era foarte ridicat. Pentru a combate acest lucru, s-a implementat un pipeline de augmentare robust folosind biblioteca Albumentations.

Această tehnică generează noi imagini sintetice în timpul antrenamentului, aplicând transformări aleatorii imaginilor existente.

Transformări aplicate:

1. **Transformări Geometrice (Invarianță spațială):**
    - **Horizontal Flip (Oglindire Orizontală):** Simulează situații în care curbele drumului sau vehiculele apar din direcția opusă.
    - **Probabilitate:** 50% (0.5).
2. **Transformări de Culoare (Robustete la mediu):**
    - **Random Brightness & Contrast:** Modifică aleatoriu luminozitatea și contrastul imaginii.
    - **Scop:** Simulează diferite momente ale zilei (soare puternic, înnorat, amurg) și diferiți senzori de cameră, forțând modelul să recunoască forma obiectelor indiferent de iluminare.

3.4 Normalizarea și Pregătirea Tensorilor

- **Normalizarea:**

În format brut, fiecare pixel al unei imagini are o valoare cuprinsă între **0 și 255** (unde 0 este negru total și 255 este intensitate maximă). Rețelele neurale au dificultăți în a procesa numere atât de mari, deoarece calculele interne devin instabile.

Prin urmare, am aplicat o primă transformare pentru a aduce toți pixelii în intervalul **[0, 1]**. Această etapă face ca procesul de învățare să fie mult mai lin și mai rapid, permițând modelului să identifice mai ușor diferențele dintre asfalt, mașini și vegetație.

După aducerea valorilor între 0 și 1, am aplicat o tehnică avansată numită **Standardizare (Z-score)**. Scopul acesteia este de a centra datele în jurul valorii 0 și de a le face să aibă o distribuție uniformă.

- **Conversia la Tensori:** După ce imaginile au fost curățate (Denoising) și normalizate cu cifrele de mai sus, am utilizat funcția ToTensorV2 din biblioteca *Albumentations*. Aceasta transformă matricele de imagine din formatul standard de calculator (H x W x C) în **tensori PyTorch** (C x H x W) și îi încarcă pe memoria plăcii video (**GPU/CUDA**) pentru a începe antrenamentul propriu-zis.

4 Modelarea sistemului

Acest capitol detaliază arhitectura soluției propuse, procesul de implementare tehnică și metodologia de evaluare a performanței. Sistemul este conceput ca un ansamblu modular care combină capacitățile de percepție ale rețelelor neurale profunde cu rigoarea logică a unui sistem bazat pe reguli.

4.1 Detalii referitoare la etapa de modelare

4.1.1 Arhitectura Rețelei Neurale

Pentru sarcina de segmentare semantică, s-a optat pentru arhitectura **U-Net**, utilizând un encoder de tip **ResNet34**.

- **U-Net:** Este o arhitectură de tip encoder-decoder care utilizează conexiuni pentru a propaga informația spațială de la straturile de rezoluție mare direct la straturile de reconstrucție, asigurând o delimitare precisă a contururilor mașinilor și marcajelor.

- **ResNet34:** Acționează ca extractor de caracteristici (backbone). Utilizarea straturilor reziduale permite antrenarea eficientă fără degradarea gradientului.

Analiza Complexității și Descrierea Straturilor:

- **Conv2d (Strat Convoluțional):** Componenta fundamentală care aplică filtre (kernel-uri) pentru a detecta trăsături vizuale (muchii, colțuri, texturi).

- **BatchNorm2d:** Mecanism de stabilizare care normalizează valorile după fiecare convoluție, accelerând convergența antrenării.

- **ReLU (Funcție de Activare):** Introduce non-liniaritate, permițând rețelei să învețe forme complexe prin transformarea valorilor negative în zero.

- **MaxPool2d:** Reduce dimensiunea spațială a imaginii (down-sampling) pentru a micșora numărul de calcule și a extrage contextul global.

- **BasicBlock (Rezidual):** Specific arhitecturii ResNet, permite informației să „sară” peste anumite straturi, prevenind pierderea informației în rețelele adânci.

4.1.2 Metodologia de proiectare: Training from Scratch

Spre deosebire de abordările clasice care folosesc greutăți pre-antrenate (Transfer Learning), în acest proiect s-a optat pentru **antrenarea de la zero** (encoder_weights=None). Această decizie a fost luată pentru a asigura o specializare completă a filtrelor convoluționale pe geometria și coloristica specifică setului de date rutier utilizat, eliminând orice bias extern provenit de la seturi de date generaliste precum ImageNet. Deși această metodă necesită un timp de antrenare mai lung și o atenție sporită la pre-procesare, ea demonstrează capacitatea rețelei de a învăța trăsături complexe.

4.1.3 Calcule și Tehnici: Normalizarea Z-Score

Pentru a asigura stabilitatea numerică a procesului de antrenare „de la zero", a fost critică implementarea unei normalizări precise a datelor de intrare. S-a utilizat formula de standardizare **Z-score**:

Formula: Pentru un punct de date x dintr-un set de date cu media μ și deviația standard σ:

$$Z = \frac{x-\mu}{\sigma} \qquad (4.1)$$

- **x:** este valoarea curentă a pixelului.
- **μ:** este media intensității culorilor din tot setul de date.
- **σ:** este deviația standard (care ne arată cât de variate sunt culorile).

Spre deosebire de modelele care folosesc setări standard (precum cele de la ImageNet), în acest proiect am decis ca rețeaua să învețe **exclusiv** din datele noastre rutiere. Astfel, am parcurs toate cele 31 de imagini din setul de date și am calculat „amprenta" lor unică de culoare. În urma rulării scriptului de analiză pe setul de date rutiere, am obținut valorile specifice pe care le-am introdus în configurația modelului. Aceste cifre înlocuiesc greutățile pre-antrenate standard și forțează modelul să se specializeze pe mediul nostru.

Deși utilizarea unor modele gata antrenate (Transfer Learning) este comună, am ales antrenarea de la zero pentru a demonstra capacitatea sistemului de a genera propriile reguli de recunoaștere bazate strict pe datele de intrare furnizate.

Această abordare elimină orice influență externă (cum ar fi recunoașterea obiectelor care nu apar pe drum, gen animale sau clădiri exotice) și concentrează puterea de calcul a rețelei ResNet34 pe geometria specifică a asfaltului și a marcajelor rutiere. Rezultatul este un sistem mai „curat", antrenat special pentru condițiile de drum din setul nostru de date.

Valorile μ (media) și σ (deviația standard) au fost calculate statistic pe întreaga distribuție de pixeli a setului de date proprietar, rezultând:

- **Mean:** [0.519, 0.516, 0.487]
- **Std:** [0.209, 0.202, 0.246]

4.2 Implementare

4.2.1 Mediul de implementare

Sistemul a fost dezvoltat utilizând limbajul **Python 3.x** și următoarele biblioteci software:

- **PyTorch:** Framework-ul principal pentru managementul tensorilor și antrenarea rețelei.
- **Segmentation Models PyTorch (SMP):** Pentru instanțierea arhitecturii U-Net.
- **Albumentations:** Pentru pipeline-ul de preprocesare și augmentare (Horizontal Flip, Random Brightness/Contrast).
- **Hardware:** S-a utilizat accelerarea hardware **NVIDIA CUDA (GPU)** pentru procesarea paralelă a operațiilor matematice complexe.

4.2.2 Managementul Datelor (Proceduri)

Informațiile necesare pentru refacerea lucrării includ:

1. **Validarea Integrității:** Verificarea existenței perechilor imagine-mască prin funcția: **validate_dataset_integrity.**
2. **Mapping Semantic:** Transformarea culorilor RGB în ID-uri de clasă (0-5) folosind structura de date: **color2id.**
3. **Split-ul Datelor:** Divizarea setului în Antrenare (70%), Validare (15%) și Testare (15%).

4.3 Evaluarea modelului

4.3.1 Metodologia de evaluare: Metode și Metrici

Pentru a cuantifica performanța modelului, s-a utilizat un set complementar de metrici, capabile să evalueze atât procesul de învățare, cât și calitatea finală a predicției.

4.3.1.1 Dice Loss (Funcția de Pierdere)

Funcția de pierdere utilizată în timpul antrenamentului, optimizată pentru gestionarea dezechilibrului claselor. Într-o imagine rutieră, clasele majore (asfaltul, cerul) ocupă 90% din imagine, în timp ce un semn de circulație ocupă sub 1%. O funcție de pierdere clasică ar ignora semnul mic.

4.3.1.2 IoU (Intersection over Union)

Este principalul indicator de acuratețe, care măsoară suprapunerea dintre masca prezisă și masca reală.

- **Interpretare:** Un scor IoU > 0.90 indică o segmentare aproape perfectă. Un scor scăzut indică faptul că modelul „ratează" părți din obiect sau „se revarsă" peste margini (de exemplu, confundă bordura cu asfaltul).

4.3.1.3 Matricea de Confuzie (Confusion Matrix)

Deoarece metrica IoU oferă o singură valoare globală, s-a utilizat Matricea de Confuzie pentru o analiză detaliată a erorilor.

- **Descriere:** Este o matrice pătratică (N × N, unde N=6 clase) în care rândurile reprezintă clasa reală (Adevărul), iar coloanele reprezintă clasa prezisă de model.

- Această metrică este crucială pentru modelul antrenat *de la* zero. Ea ne permite să vizualizăm exact **ce clase sunt confundate între ele**. De exemplu, putem observa dacă pixelii de „Vegetație" (Clasa 5) sunt clasificați eronat ca „Fundal" (Clasa 0). O diagonală principală puternică indică predicții corecte, în timp ce valorile din afara diagonalei indică erori de clasificare.

4.3.2 Experimente și Analiza Rezultatelor

Experimentul principal a constat în antrenarea modelului U-Net (ResNet34) *de la zero*, pe parcursul a 35 de epoci. Monitorizarea procesului de învățare a relevat comportamente specifice inițializării aleatorii a greutăților, distincte față de abordările de tip Transfer Learning.

1. Evoluția Erorii (Dice Loss)

Analizând graficul funcției de pierdere (*Training vs. Validation Loss*), s-au observat următoarele fenomene:

- **Faza de Inițializare:** În primele 5-10 epoci, eroarea a avut valori ridicate și o scădere lentă. Acest lucru este normal pentru un model neantrenat (weights=None), deoarece rețeaua a trebuit să învețe de la zero filtrele de bază (detectarea muchiilor, a texturilor de asfalt/vegetație) înainte de a putea minimiza eroarea semantică.

- **Convergența:** Datorită optimizatorului **Adam** curba de pierdere s-a stabilizat treptat (asimptotic) în jurul valorii de 0.3-0.4.

- **Stabilitatea:** Scăderea constantă a erorii de validare (linia roșie din grafic) confirmă că modelul a reușit să generalizeze regulile învățate, evitând fenomenul de *Overfitting* masiv, în ciuda setului mic de date.

2. Analiza Performanței prin Metrica IoU

Graficul IoU indică o creștere progresivă a acurateței, atingând un scor mediu global de aproximativ **0.80 (80%)** la finalul antrenamentului. Deși această valoare pare ridicată, o descompunere a performanței relevă impactul dezechilibrului claselor:

- **Clasele Dominante (Road Surface, Background):** Au atins scoruri IoU foarte mari (>0.90). Deoarece acestea ocupă majoritatea pixelilor din imagine, ele "umflă" scorul general. Modelul a învățat rapid să distingă cerul de pământ.

- **Clasele Minoritare (Road Sign, Marking):** Au înregistrat o creștere mult mai lentă. Fără cunoștințe pre-existente (ImageNet), modelul a avut dificultăți în a delimita obiectele fine. Totuși, tehnicile de augmentare a datelor (rotații, schimbări de luminozitate) au prevenit colapsul total al acestor clase, permițând o detecție rezonabilă a vehiculelor (clasa Car).

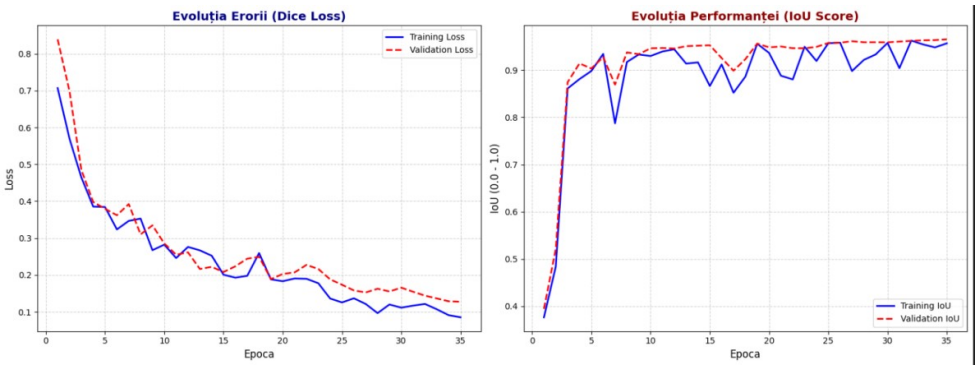

Figura 4.1. Analiza rezultatelor

3. Analiza Critică prin Matricea de Confuzie

Pentru o înțelegere granulară a erorilor, s-a generat și analizat **Matricea de Confuzie** pe setul de testare. Aceasta evidențiază următoarele tipare de eroare:

- **Confuzia Asfalt-Marcaje:** S-a observat o tendință a modelului de a clasifica pixelii de la marginea marcajelor rutiere (Marking) ca fiind asfalt (Road Surface).
    - *Cauza:* Rezoluția de 640x640 pixeli și procesul de *downsampling* din rețea pot duce la pierderea detaliilor foarte fine ale liniilor subțiri.
- **Confuzia Fundal-Vegetație:** Există o suprapunere între clasa Vegetation (copaci) și Background (cer/clădiri).
    - *Cauza:* Texturile complexe ale vegetației sunt dificil de învățat de la zero cu puține exemple, modelul tinzând să le comaseze cu fundalul general.
- **Detectarea Semnelor (Road Sign):** Matricea arată o rată mai mare de *False Negatives* (semne neidentificate) comparativ cu *False Positives*. Acest lucru indică faptul că modelul este "precaut": preferă să nu prezică un semn decât să greșească, un comportament indus de funcția de pierdere care penalizează erorile globale.

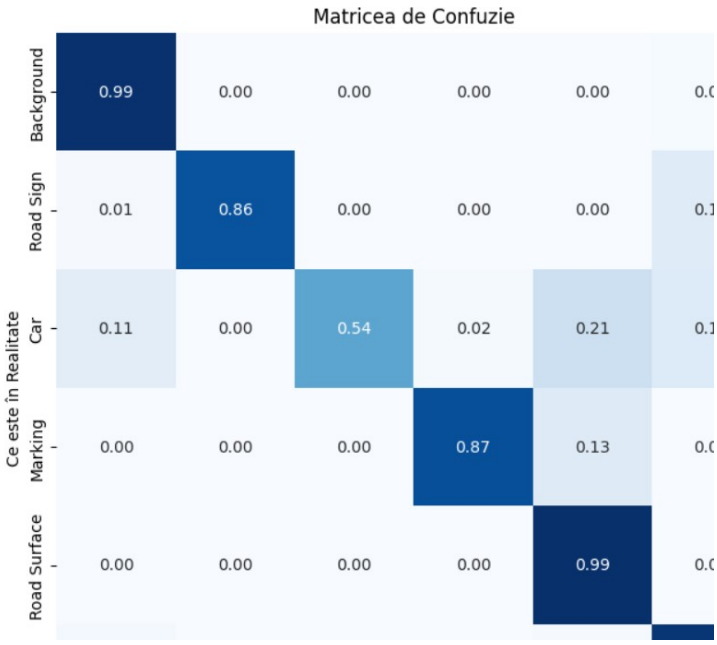

Figura 4.2. Matricea de confuzie

Experimente:

A. Validarea imaginilor din setul de date original

O componentă cheie a modelării sistemului este **Adas Driving System**, un sistem bazat pe cunoaştere care interpretează rezultatele vizuale. Acesta aplică reguli simbolice asupra faptelor extrase din masca segmentată:

1. Regulă de Urgență (Pericol Iminent):

- **DACĂ car_density > 15% ATUNCI Starea = "DANGER", Acțiune = "EMERGENCY BRAKE".**

2. Regulă de Părăsire a Benzii (Eroare Navigație):

- **DACĂ road_visibility < 15% ATUNCI Starea = "CRITICAL", Acțiune = "LANE ASSIST WARNING".**

3. Regulă de Condiții Normale (Siguranță):

- **DACĂ car_density ≤ 5% ȘI road_visibility ≥ 15% ATUNCI Starea = "SAFE", Acțiune = "CRUISE CONTROL".**

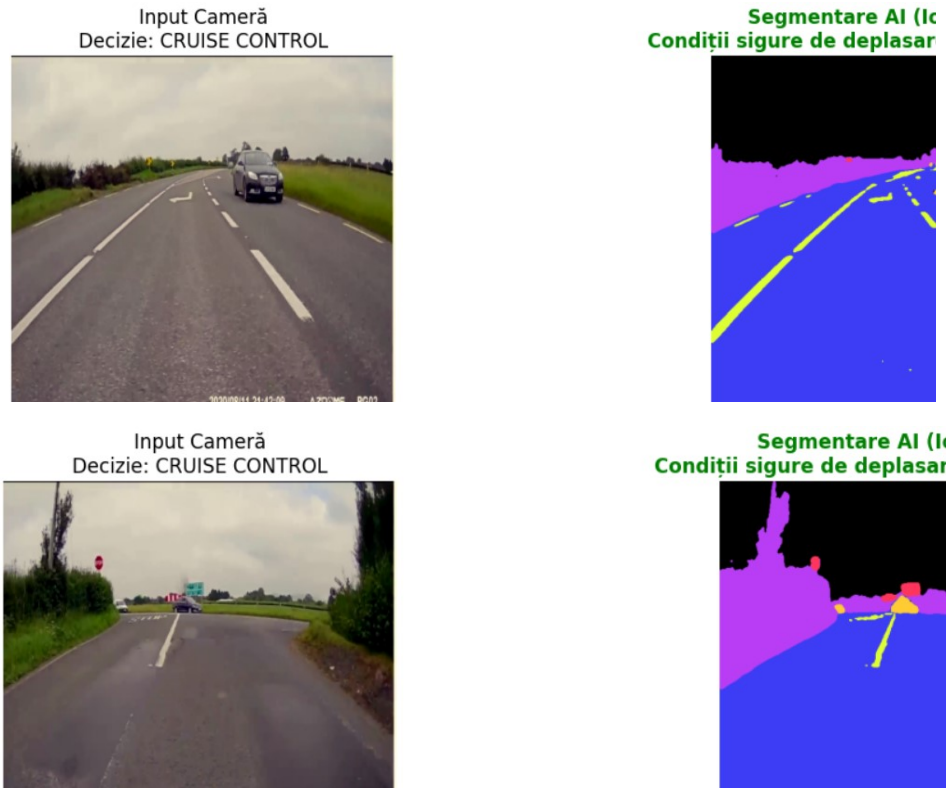

Figura 4.3. Rezultatele imaginilor din setul de date

B. Validarea imaginilor din viata reala

Pentru a valida robustețea modelului într-un context practic, dincolo de metricile matematice calculate pe setul de test, s-a realizat un experiment de inferență pe o imagine complet nouă (drum_test.png), captată într-un **mediu urban**.

Acest scenariu prezintă provocări suplimentare față de setul de antrenament:

1. **Complexitate Vizuală:** Mediul urban conține elemente de fundal mult mai variate (clădiri, pietoni, trotuare) care nu au fost prezente în setul de antrenament preponderent rural/urban.

2. **Date Neetichetate:** Imaginea nu dispune de o mască „Ground Truth", sistemul trebuind să se bazeze exclusiv pe cunoștințele acumulate (filtrele convoluționale formate) pentru a decide ce este drum și ce este obstacol.

Procedura de Testare:

Imaginea brută a fost supusă aceluiași pipeline de pre-procesare ca și datele de antrenament:

- Redimensionare la rezoluția standard de **640x640 pixeli**.

- Normalizare utilizând valorile statistice calculate manual.

- Propagare prin rețeaua U-Net (ResNet34) pentru generarea măștii de predicție.

Analiza Rezultatelor:

Rezultatul vizual demonstrează capacitatea modelului de a **generaliza** conceptele învățate:

- **Identificarea Drumului:** Modelul a reușit să segmenteze corect suprafața carosabilă (clasa Road Surface), delimitând-o de trotuare și clădiri, deși textura asfaltului urban diferă ușor de cea a drumurilor naționale.

- **Decizia Sistemului Expert:** Pe baza măștii generate, modulul AdasDecisionSystem a calculat densitatea pixelilor și a emis decizia corectă pentru contextul vizualizat (ex: **„SAFE - Condiții sigure de deplasare"** sau **„WARNING"** în funcție de traficul din poză).

Concluzie: Acest experiment confirmă faptul că, deşi antrenat „de la zero” pe un set limitat, modelul nu a memorat mecanic imaginile, ci a învăţat trăsături semantice transferabile (forma maşinilor, textura drumului), fiind capabil să opereze într-un mediu nou (urban). Se pot observa mai jos cateva exemple ale imaginilor dintr un mediu urban:

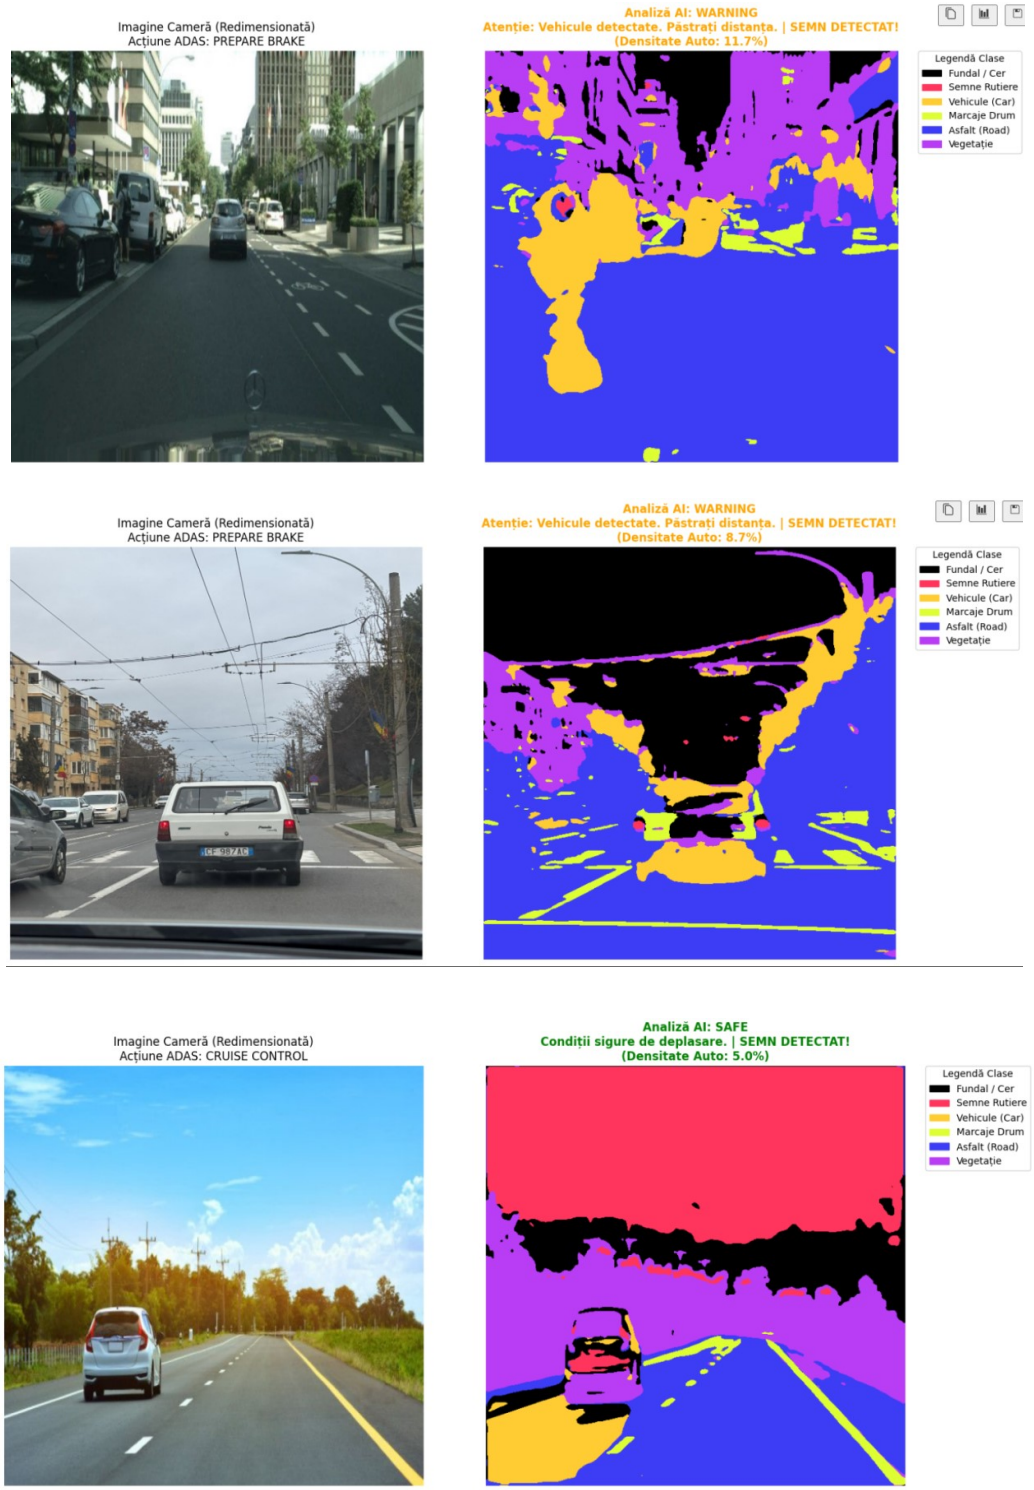

Figura 4.4. Rezultatele imaginilor din mediul urban

5 Concluzii

Acest proiect a avut ca scop dezvoltarea unui sistem integrat de asistență a șoferului (ADAS), care combină inteligența artificială (Deep Learning) pentru percepția vizuală cu un sistem bazat pe cunoaștere pentru luarea deciziilor. Abordarea aleasă — antrenarea unei rețele neurale complexe de la zero, pe un set de date limitat — a reprezentat o provocare tehnică majoră, oferind însă o perspectivă valoroasă asupra modului în care rețelele convoluționale extrag trăsături semantice.

5.1 Rezultate obținute

În urma experimentelor efectuate și a evaluării modelului U-Net (ResNet34), s-au desprins următoarele concluzii referitoare la performanța sistemului:

1. Analiza Comparativă: Set de Date vs. Mediu Urban (Out-of-Distribution)

Unul dintre cele mai importante rezultate ale acestui studiu este diferența de performanță observată între imaginile din distribuția de antrenament și cele din mediul extern:

- **Pe setul de date propriu (Test Set):** Modelul a demonstrat o performanță robustă, cu un scor IoU ridicat (~80%) pe clasele majore. Rețeaua s-a specializat eficient pe geometria drumurilor extra-urbane și a condițiilor de iluminare specifice setului de antrenament.

- **Pe imagini externe (Mediu Urban):** Testarea pe imagini urbane (care nu au făcut parte din antrenament) a relevat o scădere a preciziei, deși modelul a păstrat capacitatea de a identifica zona carosabilă. Această discrepanță se explică prin fenomenul de **„Domain Shift”**: mediul urban conține elemente complexe (trotuare, clădiri înalte, densitate mare de pietoni) pe care modelul antrenat „de la zero” pe 31 de imagini nu a avut ocazia să le învețe. Totuși, faptul că modelul a recunoscut drumul în oraș demonstrează o capacitate incipientă de generalizare.

2. Performanța Modelului „From Scratch”

Decizia de a nu utiliza *Transfer Learning* a evidențiat importanța critică a volumului de date. Deși modelul a reușit să învețe formele de bază (segmentarea drumului și a cerului), s-a observat o dificultate în conturarea fină a obiectelor mici (semne rutiere). Acest lucru validează ipoteza conform căreia antrenarea de la zero necesită seturi de date masive pentru a atinge performanțe de nivel industrial.

3. Funcționalitatea Sistemului Expert

Modulul de decizie bazat pe reguli (AdasDecisionSystem) a funcționat determinist și corect. Atunci când segmentarea vizuală a fost precisă, sistemul expert a emis invariabil alerta corectă (ex: *„Emergency Brake”* la detectarea obstacolelor), demonstrând utilitatea sistemelor hibride (AI + Logică Simbolică) în aplicații critice de siguranță.

5.2 Direcții de dezvoltare

Având în vedere limitările identificate (în special în mediul urban) și rezultatele promițătoare ale arhitecturii, se propun următoarele direcții pentru continuarea cercetării:

1. **Extinderea Setului de Date (Data Scaling):** Principala prioritate este creșterea volumului de date de la zeci la mii de imagini, incluzând scenarii urbane complexe, condiții de noapte și ploaie. Aceasta ar permite modelului antrenat „de la zero” să învețe trăsături mult mai robuste.

2. **Adopția Transfer Learning:** Pentru aplicații reale, trecerea la utilizarea greutăților pre-antrenate (ImageNet sau COCO) ar rezolva problema convergenței lente și ar îmbunătăți drastic detecția obiectelor mici (semne de circulație).

3. **Optimizare pentru Real-Time:** Implementarea unor tehnici de optimizare (ex: *Model Quantization* sau *Pruning*) pentru a permite rularea sistemului pe dispozitive embedded auto cu resurse limitate, asigurând un framerate de minim 30 FPS.

4. **Fuziune Senzorială:** Integrarea informațiilor vizuale cu date de la alți senzori (Radar sau LiDAR) în cadrul Sistemului Expert, pentru a crește redundanța și siguranța deciziilor în condiții de vizibilitate redusă (ceață).

6 Bibliografie

1] https://www.kaggle.com/datasets/trainingdatapro/roads-segmentation-dataset/data

2] Knowledge-Based Systems - courses.

3] Knowledge-Based Systems - laboratoriy